

电商评论 AI 影响力提取工具

开发要求 - 写给 Codex 的实现说明

版本：v1.2

用途：直接交给 Codex 生成和迭代脚本。

边界：第一阶段只做本地 HTML 抽取和本地规则筛选，不联网，不调用大模型。

1. 项目目标

开发一个 Python 本地脚本，批量处理已经用 Chrome 插件 SingleFile 保存下来的电商商品页面 HTML 文件。脚本从本地页面中提取消费者评论、淘宝“问大家”、京东“大家评/买家评价”，再用本地关键词和规则筛出可能与 AI 信息来源有关的内容，输出 Excel 供人工复核。

- 本项目不是爬虫：页面已经保存到本地，脚本不得访问淘宝、京东或任何外部网站。
- 第一阶段不调用大模型 API：AI 相关判断只使用 keywords.yaml 与规则。
- 核心输出不是结论报告，而是结构化数据表：评论、问答、候选、错误、debug 样本。
- 所有判断必须能回到原始文本、来源文件、商品标题和命中关键词。

2. 处理流程

本地 SingleFile HTML
→ 平台识别
→ 商品信息提取
→ 评论 / 问大家 / 大家评提取
→ 文本清洗
→ 去重
→ 购前决策标注
→ AI 候选规则筛选
→ 证据等级 A/B/C/D
→ 多 Sheet Excel 输出

3. 命令行与运行方式

```
python main.py \  
--input "./html_pages" \  
--output "./output/ai_related_reviews.xlsx" \  
--keywords "./config/ai_keywords.yaml" \  
--recursive
```

- --input：输入文件夹，必填。
- --output：输出 Excel 文件路径，必填。
- --keywords：关键词配置文件，默认 ./config/ai_keywords.yaml。
- --recursive：是否递归读取子文件夹。
- --debug：是否输出 debug 样本，默认 True。
- --max-files：调试用，限制最多处理多少个 HTML。

4. 项目目录建议

```
ecommerce_ai_comment_extractor/  
main.py  
requirements.txt  
README.md  
config/  
ai_keywords.yaml  
extractor/  
platform_detect.py  
html_loader.py  
product_meta.py  
taobao_qa.py  
taobao_reviews.py  
jd_reviews.py  
generic_blocks.py  
analysis/  
ai_keyword_matcher.py  
pre_purchase.py  
evidence_rules.py  
summary.py  
utils/  
text_cleaner.py  
dedupe.py  
excel_writer.py  
logger.py  
output/
```

requirements.txt

```
beautifulsoup4  
lxml  
pandas  
openpyxl  
pyyaml  
tqdm
```

5. 平台识别

实现 `detect_platform(html_text, file_path) -> str`。返回值包括 `taobao`、`tmall`、`jd`、`pdd`、`douyin`、`unknown`。第一阶段优先稳定支持淘宝/天猫和京东。

平台	识别线索	第一阶段解析重点
淘宝/天猫	taobao.com、tmall.com、淘宝、天猫、问大家、已买到的宝贝	问大家、商品评价、问题标签、问题-回答配对
京东	item.jd.com、-京东、大家评、买家评价、jdc-pc-rate-card	大家评/买家评价、评价标签、可见评价卡片
未知	无法稳定识别	只做 generic 文本候选，不进入高置信结果

6. 商品基础信息提取

每个页面必须至少保留 `source_file` 和 `platform`。其他信息尽量提取，提取不到允许为空，但不能中断流程。

```
source_file  
platform  
product_title  
shop_name
```

```
product_url
product_id
page_title
```

京东 product_id 可从 item.jd.com/数字.html 提取。京东商品标题优先从 <title> 提取，并去掉 “【行情 报价 价格 评测】-京东 ” 等尾巴。

7. 数据对象与核心 Sheet

7.1 reviews_raw：普通商品评价

```
source_file, platform, product_title, shop_name, product_url, product_id,
review_order, review_text_raw, review_text_clean, review_time, rating, sku,
user_name_masked, is_followup, followup_text, merchant_reply,
image_count, video_count, like_count, review_hash, extract_confidence, review_source
```

7.2 qa_pairs_raw：淘宝问大家

```
source_file, platform, product_title, shop_name, product_url, product_id,
qa_order, question_text_raw, question_text_clean, answer_text_raw, answer_text_clean,
answer_user_status, answer_count, question_tags, is_buyer_answer, qa_hash, extract_confidence
```

7.3 content_all：统一内容表

```
content_id, record_type, source_file, platform, product_title, shop_name, product_url, product_id,
content_role, content_text_raw, content_text_clean, parent_text_clean, sku, user_name_masked,
user_status, content_order, content_hash,
pre_purchase_decision, pre_purchase_terms, pre_purchase_reason,
ai_candidate, ai_candidate_gate_reason, ai_source_terms, ai_action_terms,
purchase_context_terms, decision_context_terms, matched_keywords, matched_sentence,
match_score, evidence_level, evidence_reason, excluded_by_rule, exclude_reason, extract_confidence
```

7.4 ai_candidates：AI 相关候选结果表

只保留 evidence_level 为 A/B/C 的记录。D 级不得进入 ai_candidates。排序规则：A -> B -> C，然后 match_score 降序。

8. 淘宝 / 天猫解析要求

淘宝第一优先级是 “问大家”，因为它天然代表购买前疑问。问大家需要提取问题、首条回答、已购标记、回答数和页面标签。

- 找到包含 “问大家” 的主区域。
- 提取顶部标签，例如：全部:1605;质高:74;好用:49;灯光:33;效果:33;刺眼:29;眼睛:18。
- 每个问答卡片尽量配对 question_text 与 answer_text。
- 如果无法稳定配对，不丢弃，写入 debug_samples。
- 去掉 “查看全部回答、展开、收起、更多” 等操作文案。

9. 京东解析要求

京东样本显示，第一阶段应优先解析 “大家评 / 买家评价”，不要照搬淘宝 “问大家”。京东页面可能有评价标签、评价预览和完整评价卡片，但 SingleFile 只保存当前已渲染评论，不代表全部评论池。

9.1 京东评价字段

- review_source = jd_rate_card：从 .jdc-pc-rate-card 抽取。
- user_name_masked = .jdc-pc-rate-card-nick。
- user_status = .jd-content-pc-tag，例如 “该店铺购买 ≥ 2 次”。

- review_time = .date.list。
- sku = .info。
- review_text_clean = .jdc-pc-rate-card-main-desc。
- image_count = .jd-content-pc-media-list-item 数量。
- review_source = jd_preview_comment：从 #comment-root 的预览评价抽取。

9.2 京东评价标签

提取评价标签到 jd_review_tags，例如：光线柔和和不刺眼:237;适合儿童使用:45;灯光效果超惊艳:101。

9.3 京东质量提示

declared_review_count = 从“买家评价(1万+)”提取
saved_comment_card_count = 实际抽出的评论卡片数量
如果 declared_review_count 很大但 saved_comment_card_count 很小，写入 debug 或 summary：
“该 JD 页面只保存了当前可见/已渲染评价，不能代表完整评论池。”

9.4 京东 AI 误判风险

京东页面自身可能包含 AI 搜索按钮、AI 搜索 class、智能推荐 UI。必须先抽出消费者评论正文，再做 AI 关键词匹配。
严禁对整个 HTML 做 AI 关键词匹配。

10. 文本清洗

clean_text(text) 必须保留消费者原话。不要删除“智商税、太贵、真香、后悔、推荐”等情绪和决策词。

去掉：查看全部回答、查看全部、展开、收起、查看更多、更多、默认好评、孤立省略号。
合并：多余空格、多余换行。
保留：品牌词、型号词、AI词、价格/风险/选择词、原始标点。
同时保存 raw_text 与 clean_text。

11. 关键词配置 ai_keywords.yaml

必须拆分 AI 入口词、AI 行为词、购买语境、决策语境、人工服务来源和排除词。AI 行为词与决策词不能单独触发 AI 候选。

```
ai_sources_strong:
- 豆包
- DeepSeek
- deepseek
- ChatGPT
- chatgpt
- GPT
- Kimi
- 通义千问
- 文心一言
- 腾讯元宝
- Gemini
- Copilot

ai_sources_generic:
- AI
- A.I.
- AI助手
- ai助手
- 人工智能
- 智能助手
- 智能问答
```

- AI搜索

ai_actions:

- 推荐
- 建议
- 对比
- 比较
- 分析
- 帮我选
- 让我买
- 告诉我
- 查了
- 搜了

purchase_context:

- 买
- 购买
- 入手
- 下单
- 最后选
- 直接下单

decision_context:

- 怎么选
- 选哪个
- 推荐哪个
- 值不值
- 智商税
- 有必要买吗
- 怕踩坑
- 做攻略
- 没做攻略

human_service_sources:

- 客服
- 售前
- 售后
- 导购
- 店家
- 商家
- 朋友
- 同事
- 家人

12. 核心判断：购前决策与 AI 候选必须拆开

关键原则：购前决策相关 ≠ AI 相关候选。

pre_purchase_decision 用来定义 “ AI 可能介入的场景母集 ” ；ai_candidate 才表示 “ 这条内容可能与 AI 信息入口有关 ” 。
一条评论可以属于购前决策母集，但不进入 AI 候选。

字段	含义	触发条件
pre_purchase_decision	是否购前决策相关	选择、比较、做攻略、值不值、智商税、推荐哪个、适不适合等
ai_candidate	是否 AI 相关候选	必须有 AI 来源词、AI助手、智能问答、算法/系统/智能推荐等 AI 入口信号

evidence_level	AI 证据等级	仅围绕 AI 入口与决策路径判断，不把普通卖点体验判为 C
----------------	---------	-------------------------------

13. AI候选 Gate 规则

ai_candidate 只有在以下情况才为 True：

- 命中强 AI 来源词：豆包、DeepSeek、ChatGPT、Kimi、通义千问、文心一言、腾讯元宝、Gemini、Copilot 等。
- 命中安全 AI 通用词：AI助手、智能助手、智能问答、AI搜索、人工智能等。
- 命中弱 AI/算法入口词：算法推荐、系统推荐、智能推荐，并且与购买/选择/推荐语境同句或近邻。

以下词不能单独触发 ai_candidate：推荐、比较、选择、值不值、适合、孩子、不刺眼、反光、护眼、买之前。它们只能辅助计算购前决策或提升 match_score。

14. A-D 证据等级

等级	定义	示例	进入 ai_candidates
A	明确 AI 决策路径：AI 来源词 + 推荐/比较/分析/选择/购买动作	豆包和 DeepSeek 都推荐了这一款，没做攻略就直接下单了。	是
B	明确 AI 来源，但决策动作不完整	之前在豆包里看到过这个牌子。	是
C	弱 AI / 算法推荐语境：没有明确平台名，但出现智能助手、智能问答、算法推荐、系统推荐等入口	智能助手推荐的，买回来还可以。	是
D	非 AI 相关：普通体验、普通卖点、客服咨询、普通推荐、比较满意、比较适合	买之前问客服比较细；光比较柔和；推荐给大家。	否

15. 特殊误判处理

15.1 AI 与 Air

不要把 Air / air / chair / pair / rain 等英文单词误判为 AI。小写 ai 只在“ai助手、ai推荐、问ai、用ai、让ai”等上下文中匹配。

15.2 “比较”

不算比较行为：比较满意、比较适合、比较简单、比较柔和、比较亮、比较舒服、比较负责、比较好看、比较不错。

算比较/选择行为：对比了很多家、比较了几款、和某品牌比、跟某品牌对比、几个品牌比较下来、纠结很久、做了很多攻略。

15.3 “推荐”

不算 AI：真心推荐给大家、值得推荐、推荐购买、推荐给朋友、不推荐。

算 AI 候选：豆包推荐、DeepSeek推荐、AI推荐、智能助手推荐、算法推荐、系统推荐。

15.4 客服 / 人工来源

如果命中“问客服、咨询客服、售前解答、导购推荐、商家推荐”，则 pre_purchase_decision=True 也可以，但 ai_candidate=False，evidence_level=D。

16. 购前决策母集判断

pre_purchase_decision 的作用是计算合理分母，不是证明 AI 影响。狭义购前决策包括：比较/选择、攻略/信息搜集、风险/价值判断、效用/适配疑问。

类别	关键词/模式	说明
比较/选择	对比了很多、比较了几款、最终选择、纠结、选哪个、怎么选	用户在筛选候选商品
攻略/信息搜集	做攻略、做功课、查参数、看了很多、问了很多	用户在降低信息成本
风险/价值判断	智商税、值不值、贵不贵、性价比、物有所值、踩坑	用户在判断购买风险
效用/适配疑问	有用吗、适合孩子吗、推荐买吗、后悔吗	用户在判断是否适合自己

17. 去重规则

```
content_hash = md5(platform + product_id + content_role + content_text_clean + parent_text_clean)
qa_hash = md5(platform + product_id + question_text_clean + answer_text_clean)
review_hash = md5(platform + product_id + review_text_clean + review_time + sku)
```

如果 product_id 为空，使用 source_file 兜底。去重后保留第一次出现的记录。

18. Excel 输出

- ai_candidates：A/B/C 级候选，核心结果表。
- content_all：所有评论、问题、回答统一表。
- qa_pairs_raw：淘宝问大家原始配对表。
- reviews_raw：普通评价原始表，淘宝和京东都进入这里。
- jd_review_tags：京东评价标签，如果有。
- summary_by_product：商品维度汇总。
- summary_by_keyword：关键词维度汇总。
- pre_purchase_details：购前决策母集明细。
- errors：解析失败记录。
- debug_samples：低置信度配对、虚拟滚动不足、疑似误判样本。

19. 日志与质量提示

开始处理文件数量
 当前文件名
 平台识别结果
 商品标题
 提取评论数量
 提取问答数量
 content_all 数量
 pre_purchase_decision 数量
 ai_candidates 数量
 A/B/C/D 数量
 JD declared_review_count 与 saved_comment_card_count
 错误文件数量
 输出文件路径

20. 验收测试

下列样本不得进入 ai_candidates，均应为 D 级。

买的110w的，亮度足。光线柔，不刺眼。但是如果桌面有透明的桌布隔热垫，会有点反光，我把隔热垫拿掉了。总之，比较满意。

灯收到了，亮度可以调节，比较适合孩子们，外观也漂亮。

客服月夜很负责，买之前和之后，我问的比较细，客服都耐心的解答，非常不错。

灯一开房间很亮，光比较柔和，这是买的第二台了。

大路灯收到有几天了，自己安装的，比较简单，有了这个大路灯孩子写作业不用担心了。

下列样本应进入 ai_candidates。

豆包和DeepSeek都给我推荐了这一款，没做攻略就直接下单了。 -> A

找豆包推荐的产品，真的很不错。 -> A/B，视购买动作是否明确

之前在AI助手里看到过这个牌子。 -> B

智能助手推荐的，买回来还可以。 -> C

系统推荐我看的这款，纠结后下单了。 -> C

21. 第一阶段交付标准

- 脚本可以在本地运行，不访问网络。
- 可以批量处理 SingleFile HTML。
- 淘宝问大家可以提取为问题和回答。
- 京东大家评/买家评价可以提取可见评价与评价标签。
- content_all 同时包含 review / question / answer。
- pre_purchase_decision 与 ai_candidate 被拆开。
- 普通“比较满意、比较适合、客服咨询、推荐给大家”不会误判为 AI 候选。
- AI / Air 不误判。
- Excel 可以追溯到原文、来源文件、商品、命中词、命中句子、证据等级。
- errors 与 debug_samples 能帮助继续迭代 parser。